1. 前史: VLA はどうやって生まれたか

RT-2（2023.07）が「VLA（Vision-Language-Action model）」という用語を定義し、その最初の実装を示した。RT-2の設計は**2つの独立した系譜の合成**である：

1. **ロボット学習プロトコルとデータ（RT-1起点）** — 行動の離散化（256bin）、大規模デモデータ（13万エピソード）、評価プロトコル。RT-2はこれらをRT-1から継承した
2. **Web規模の事前学習済みVLM（PaLI-X / PaLM-E起点）** — RT-2は既存VLMを出発点に、行動をテキストトークンとして出力させることで、VLMのWeb知識を低レベルロボット制御に直接転用した

RT-2の核心的イノベーションは「行動のトークン化（action tokenization）」— ロボットの連続行動をVLMのトークナイザに載る文字列として表現し、VLMの自然言語出力と同じ枠組みで行動を生成させたこと。さらに、ロボットデモデータとWebのVLMデータ（VQA等）を混ぜるco-fine-tuningにより、汎化性能を大幅に向上させた。

1.1 ロボット学習のスケーリング: RT-1が作った土台

RT-2が継承した**ロボット側の系譜**。行動の離散化、大規模デモデータ収集、言語条件付きマルチタスク学習といったプロトコルは、以下の研究を経てRT-1で確立された。事前学習済みVLMをバックボーンとして使っていない。

※ 年はarXiv v1投稿日基準。

arXiv投稿日	手法	著者・所属	役割	核心的貢献
2021-06-02	**Decision Transformer**	Chen et al. (UC Berkeley)	**系列モデリングの転換**	RLを「return-conditionedな系列生成」に再定式化（NeurIPS 2021）。評価はAtari/OpenAI Gym中心で、ロボット操作そのものが主題ではない
2021-06-03	**Trajectory Transformer**	Janner et al. (UC Berkeley)	**系列モデリング（計**	DTの翌日に投稿。同じく軌跡の系列モデリングだが、ビームサーチで「計画」する発想が中核（NeurIPS

arXiv投稿日	手法	著者・所属	役割	核心的貢献
			画寄り）	2021 spotlight）。RT-1が両者を"着想源"として明示的に引用
2021-09-24	**CLIPort**	Shridhar et al. (UW/NVIDIA)	**VLM→ロボットの橋渡し**	CLIPの意味理解（what）+TransporterNetの空間精度（where）を融合。10シミュレーション+9実機タスクのマルチタスクポリシー。**事前学習済みVLMの知識をロボット制御に転用する先駆**（CoRL 2021）
2022-02-04	BC-Z	Jang et al. (Google)	言語条件付けBC	100タスク・25,877エピソードでの言語条件付きゼロショット汎化。事前学習済みsentence encoder（USE系）で512次元埋め込み→FiLMでポリシーを条件づけ
2022-03-23	**R3M**	Nair et al. (NYU/Meta)	**視覚表現の事前学習**	Ego4D動画から時間対照学習+動画言語アライメントでロボット操作用の視覚表現を学習。RT-2が先行研究として明示的に引用・比較
2022-05-12	Gato	Reed et al. (DeepMind)	マルチタスク統合	604タスク（制御系596+VL/言語8）を1つのTransformerで学習。ただし実機ロボットタスクはRGB Stacking（Sawyer）の1タスクのみ。「汎用エージェント」の概念を提示
2022-12-13	**RT-1**	Brohan et al. (Google)	**スケーリングの実証**	**13ロボット・13万エピソード・744タスク**でTransformerを学習。スケーリングの有効性を実証。**VLAの直接的な土台**

> **なぜRT-1はVLAではないのか？**
>
> RT-1のアーキテクチャは論文本体で以下のように明示されている：
>
> ```
> RT-1のアーキテクチャ（論文記載に基づく）：
> ```

>
> ```
> 画像(6枚) → ImageNet事前学習 EfficientNet-B3 ─┐
>                  ↑ FiLM層で言語条件づけ            │
> 言語指示 → Universal Sentence Encoder(512d) ────┘
>                                                    ↓
>                                        "vision-language tokens"
>               (言語で条件づけた視覚トークン)
>                                                    ↓
>                                              TokenLearner
>                  (トークン数を圧縮)
>                                                    ↓
>                                        Decoder-only Transformer (8層)
>                                                    ↓
>                  トークン化された行動
> ```
>
> 視覚はImageNet事前学習のEfficientNet-B3、言語はUSE埋め込みという**別系統の事前学習器をFiLMで結合**する設計。RT-1論文中で "vision-language tokens" という語を使うが、これは「言語で条件づけた視覚トークン」の意であり、Web規模で事前学習された統合VLMとは異なる。
>
> RT-2はRT-1の行動離散化プロトコルとデータを継承しつつ、モデル自体は既存VLM（PaLI-X 55B / PaLM-E 12B）を出発点とした。行動をVLMのテキストトークンとして表現し、ロボットデモとWebデータのco-fine-tuningでVLMのWeb知識がロボット制御に転移することを実証した。

RT-2が継承したもの（引用関係で検証済み）:

RT-1論文はDT/TTを**明示的に"着想源"と記述**しており、系列モデリングの発想がRT-1の設計に直接影響している。RT-2はRT-1から以下を継承した：

- **行動離散化プロトコル**: 各連続次元を256binに離散化してトークン列として出力する方式
- **デモデータセット**: RT-1由来の13万エピソード（モバイルマニピュレータ、7スキル種別）
- **評価プロトコル**: 同一環境での汎化評価。RT-2はRT-1の32%→62%（Unseen Average）と改善を報告

一方、CLIPort・R3MはRT-2論文で先行研究として引用されており、「事前学習済みモデルの知識はロボットに転用できる」ことを示した前例として位置づけられている。

1.2 VLMの成熟: RT-2のモデル側の系譜

RT-2が**モデルの出発点**としたのは、PaLI-X（55B）とPaLM-E（12B）という2つの既存VLMである。RT-2は「新しいパラメータを追加せずに、既存VLMから行動を出力させる」と明記しており、VLMの成熟がVLA実現の前提条件だった。

特にPaLM-E（2023.03、RT-2より4か月先行）は、連続センサ入力をLLMのトークン空間に注入する「Embodied MLLM」として、RT-2の概念的先行者でもある。RT-2はPaLM-Eの「multimodal sentences」という枠組みを参照しつつ、出力を高レベル計画ではなく低レベル行動に拡張した。

VLAの性能は (1) Vision Encoderの視覚表現の質、(2) LLMの表現力、(3) 両者の接続方法 に強く依存する。

Vision Encoderの系譜

VLAが使うVision Encoderは単純なViTではなく、学習方法の違いで複数の系統がある。

年	モデル	著者・所属	学習方法	核心的貢献
2020	**ViT**	Dosovitskiy et al. (Google Brain)	教師あり分類	画像をパッチ→トークンでTransformer処理。視覚表現のパラダイムシフト（arXiv: 2020-10、ICLR 2021採択）
2021	**CLIP ViT**	Radford et al. (OpenAI)	対照学習（softmax）	4億画像-テキストペアで対照学習。視覚-言語共通埋め込みの確立（arXiv: 2021-02-26）
2023	**DINOv2**	Oquab et al. (Meta)	**自己教師あり学習**	言語ラベルなしで画像だけから空間的・局所的な視覚特徴を学習。**低レベルの空間情報（把持点・物体境界等）に強い**
2023	**SigLIP**	Zhai et al. (Google)	対照学習（**sigmoid**）	CLIPのsoftmax正規化をpairwise sigmoid lossに変更。バッチサイズに依存しにくく、fine-tuneしても視覚表現が崩れにくい（arXiv: 2023-03-27）
2024	**SigLIP2**	Google	対照学習 + 自己教師あり + captioning	SigLIPに自己教師ありloss・captioningベース事前学習・オンラインデータキュレーショ

年	モデル	著者・所属	学習方法	核心的貢献
				ンを統合。汎用性がさらに向上

VLAでSigLIPが主流になりつつある理由:

- PaLI-3がSigLIP事前学習ViTと分類事前学習ViTを比較し、マルチモーダル（特にlocalizationや視覚的テキスト理解）でSigLIPが優位と報告
- PaliGemma / PaliGemma 2がSigLIP-So400mを標準採用 → π0, SpatialVLAに直結
- fine-tune時にsoftmax正規化（CLIPの弱点）が不要なため、ロボットデータでの追加学習で表現が崩れにくい

OpenVLAがSigLIPとDINOv2を併用する理由:

- SigLIP = **高レベルの意味情報**（「これはりんごだ」）
- DINOv2 = **低レベルの空間情報**（「ここに掴める面がある」）
- Prismatic VLMsの研究で、この2つのfused backbonesが設計全体の性能を押し上げることを確認

VLMの系譜（VLAのバックボーン）

VLMには「Vision EncoderとLLMをどう結ぶか」で複数のアーキテクチャパターンがある。

アーキテクチャパターン

パターン	代表	構造	VLAとの相性
Dual Encoder型	CLIP	画像とテキストを別々にエンコード→共通空間	△ 生成タスクに弱い
Encoder-Decoder型	PaLI系	Vision Encoder + テキストDecoder	○ 生成可能だがやや古い
Decoder-only + Visual Tokens型	LLaVA, PaliGemma	Vision EncoderのトークンをLLMに入力	**◎ VLAで主流**
Q-Former接続型	BLIP-2	学習可能なクエリで視覚情報を圧縮→LLMへ	△ 圧縮で情報が落ちうる
統合VLM型	Qwen-VL	Vision Encoder + LLMを最初から統合設計	◎ 設計の自由度が高い

VLAでDecoder-only型が有利な理由:

1. RT-2が示したように、行動をテキストトークンと同形式にすると学習目標が「次トークン予測」に自然に落ちる → Decoder-only LMの学習形式と整合
2. VLM側（Llama 2, Gemma等）のスケールや指示追従能力をそのまま制御に転用しやすい
3. VLMを「特徴抽出器」としても「生成器」としても扱える柔軟性がある

PaLI系の系譜（Google → VLAの主要バックボーン）

```
PaLI (2022.09)          PaLI-X (2023.05)         PaLI-3 (2023)
ViT-e(4B) + mT5    →   ViT-22B + 大規模化    →  SigLIP ViTが優位と実証
                          ↓ RT-2のバックボーン
                                                      ↓
                                                 PaliGemma (2024.07)
                                                 SigLIP-So400m + Gemma-2B
                    軽量・オープン・転移重視
                                                 ↓ π0 / π0-FASTのバックボーン
                                                      ↓
                                                 PaliGemma 2 (2024.12)
                                                 SigLIP-So400m + Gemma 2 (2B〜27B)
                    複数解像度(224/448/896)で段階学習
                                                 ↓ SpatialVLAのバックボーン
```

要点:「PaLI/PaLI-X（巨大・専用）→ PaliGemma（小型・オープン・転移重視）→ PaliGemma 2（多様なサイズ&解像度）」という、実運用・研究展開のしやすさに寄った分岐。

その他のVLA関連VLM

年	モデル	著者・所属	核心的貢献	VLAとの関係
2022	Flamingo	Alayrac et al. (DeepMind)	凍結VisionEncoder + LLMをPerceiver Resamplerで接続。Few-shot VLMのテンプレート確立	アーキテクチャパターンの先駆
2023	**PaLM-E**	Driess et al. (Google)	連続センサ入力をLLM入力に混在させるEmbodied MLLM。**RT-2のもう一つのバックボーン**	VLMだけでなくEmbodied MLLMもVLAの背骨になりうることを実証
2023	**LLaVA**			

年	モデル	著者・所属	核心的貢献	VLAとの関係
		Liu et al. (UW/ Microsoft)	CLIP ViT + Vicuna を線形射影で接続。シンプルなアーキテクチャでGPT-4Vに迫る性能	Decoder-only + Visual Tokens型の代表。VLA設計の参照点
2023	BLIP-2	Li et al. (Salesforce)	Q-Formerで凍結エンコーダとLLMを効率的に橋渡し	Q-Former型の代表
2024	**Prismatic VLMs**	Karamcheti et al. (ICML 2024)	VLMの設計軸を系統評価。SigLIP + DINOv2のfused backbonesが有効と実証	**OpenVLAのバックボーン（Prismatic-7B）**
2023–	**Qwen-VL系**	Alibaba	動的解像度・マルチモーダルRoPE等を導入したVLMシリーズ（Qwen-VL → Qwen2-VL → Qwen3-VL）	**VLANeXtの最終設定がQwen3-VL 2Bを採用。**CoA-VLAのDi-VLAもQwen2-VLを統合
2023–	**InternVL**	Shanghai AI Lab	6B規模のvision foundation modelをスケール。LLMと整合	VLA-Critic（InternVL上に報酬/批評を統合）で利用

LLMのロボット応用（VLAとは異なるアプローチ）

VLMをバックボーンに使うのではなく、LLMを「ロボットの知恵袋」として外部利用する試み。VLAとは別系統だが、「言語モデルの知識がロボットに有用である」ことを示した重要な前例。

年	手法	著者・所属	核心的貢献
2022	**SayCan**	Ahn et al. (Google)	LLMがプラン提案、value functionが実行可能性をスコアリング。**LLM知識のロボットへの接地（grounding）**。ただし行動生成は別のポリシーが担当
2023	Code as Policies	Liang et al. (Google)	LLMにロボット制御コード（Python）を直接生成させる。行動値ではなくコードを出力

まとめ: 2つの系譜がRT-2で合成された

2023年までにVLMは「Vision Encoderの高品質化（SigLIP）」「Decoder-onlyアーキテクチャの確立」「PaLI系のスケーリング」「PaLM-Eによる身

体性タスクへの接続」を通じて十分に成熟した。RT-2はこの成熟したVLM（PaLI-X / PaLM-E）をモデルの出発点とし、RT-1が確立したロボット学習プロトコル（行動離散化・大規模デモデータ）を接続することで、VLAを実現した。SayCan/Code as Policiesは「LLMの知識はロボットに役立つ」という確信を与えた前例。

VLAの誕生図

```
■ ロボット学習プロトコル/データ          ■ Web規模VLM
──────────────────────────              ──────────────

DT/TT (2021)                              ViT (2020)
「Transformerで行動系列を生成」          CLIP (2021) → SigLIP (2023)
         │ ※RT-1が"着想源"と明記   PaLI (2022) → PaLI-X (2023)
         ↓                                       │
┌──────────────────┐                  PaLM-E (2023.03)
│  RT-1 (2022.12)  │                  Embodied MLLM
│  行動離散化(256bin) │                「連続センサ入力をLLMへ注入」
│  13万ep / 744タスク │                "multimodal sentences"
│  ※VLAではない     │                        │
└──────────┬───────┘                        │
           │                                 │
           │  プロトコル/データ               │  モデル/重み
           │  を継承                          │  を出発点に
           │                                 │
           └──────────┬──────────────────────┘
                      │
                      ↓  action tokenization
┌──────────────────────────────────────────────┐
│          RT-2 (2023.07) = VLA 誕生            │
│                                               │
│  ・行動をVLMのテキストトークンとして表現        │
│  ・ロボットデモ + Web VLMデータのco-fine-tune  │
│  ・「VLA」というカテゴリを定義                 │
│  ・バックボーン: PaLI-X 55B / PaLM-E 12B      │
│  ・汎化: RT-1の32% → RT-2の62% (Unseen Avg)   │
└──────────────────────────────────────────────┘
```

読み方: RT-2は「RT-1の改良版」ではなく、**ロボット学習プロトコル/データ（RT-1起点）** と **Web規模VLM（PaLI-X/PaLM-E起点）** の合成として生まれた。RT-2の核心的イノベーションは、両者を繋ぐ「action tokenization」— 行動をVLMのトークン列として表現し、同一の枠組みで学習・生成させたこと。